UNIVERSIDAD DEL MAGDALENA – ESP.MACHINE LEARNING APLICADO

Pruebas Saber 11 en Santa Marta

2015–2025

Rafael Mendoza-Ureche · Sheimy Lozano-Bustamante · Camilo Benavides-Jiménez

SELECCIÓN DEL DATASET

Los datos que usamos

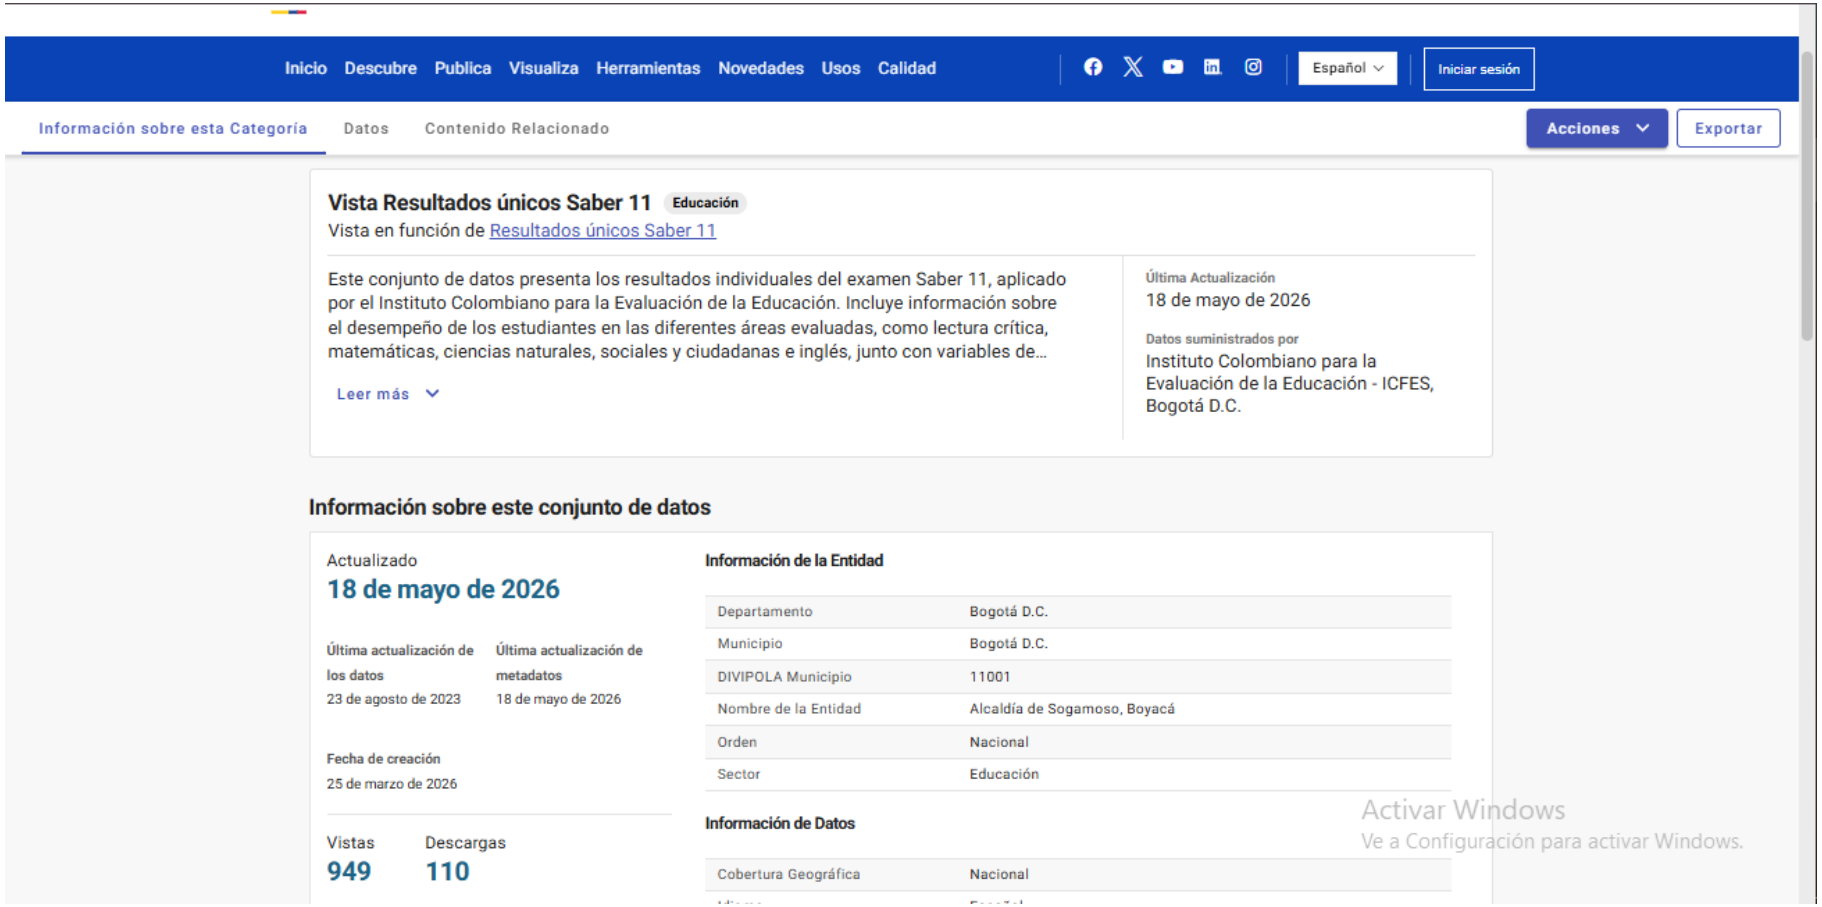
74.973
registros

32
variables

22
archivos Parquet

2015–2025
11 años de datos

Datos abiertos – Datos.gov.co



PREGUNTAS ANALÍTICAS

Tres preguntas que nos hicimos

1

¿Qué tendencia siguió el puntaje de las instituciones entre 2015 y 2025?

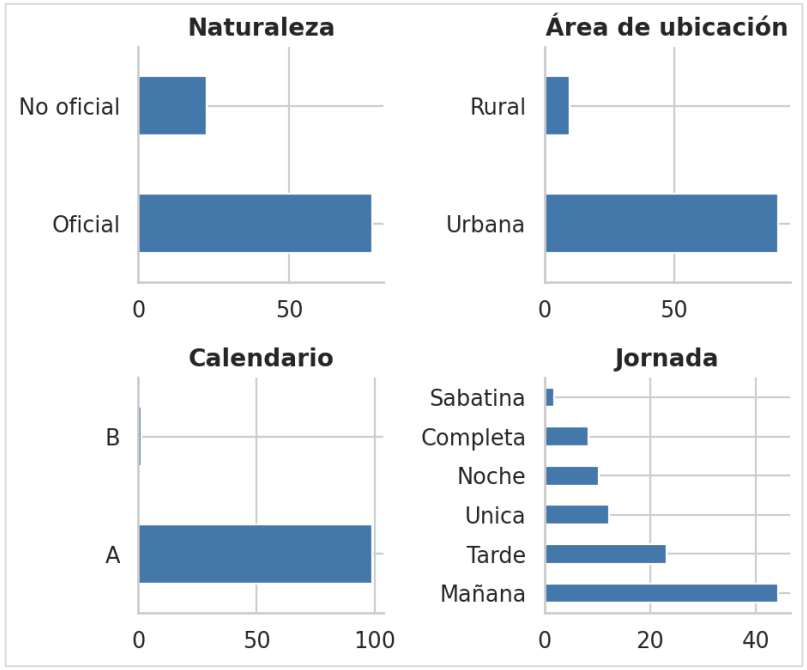
2

¿Existe diferencia entre los colegios oficiales y no oficiales?

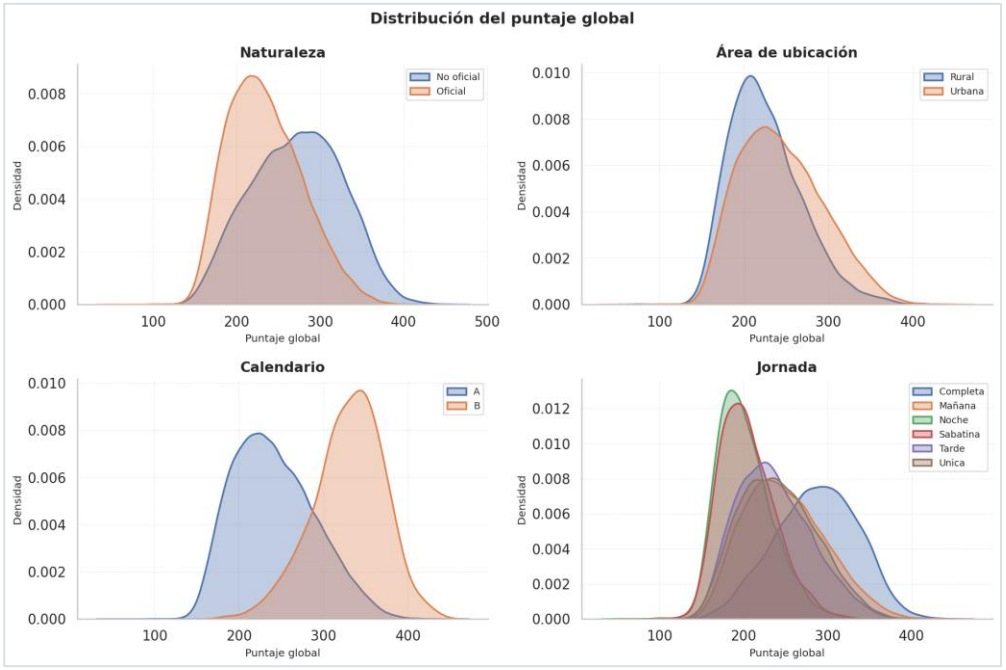
3

¿Qué relación tienen las condiciones socioeconómicas con el desempeño?

ANÁLISIS EXPLORATORIO



Distribución de instituciones



Puntaje global por característica

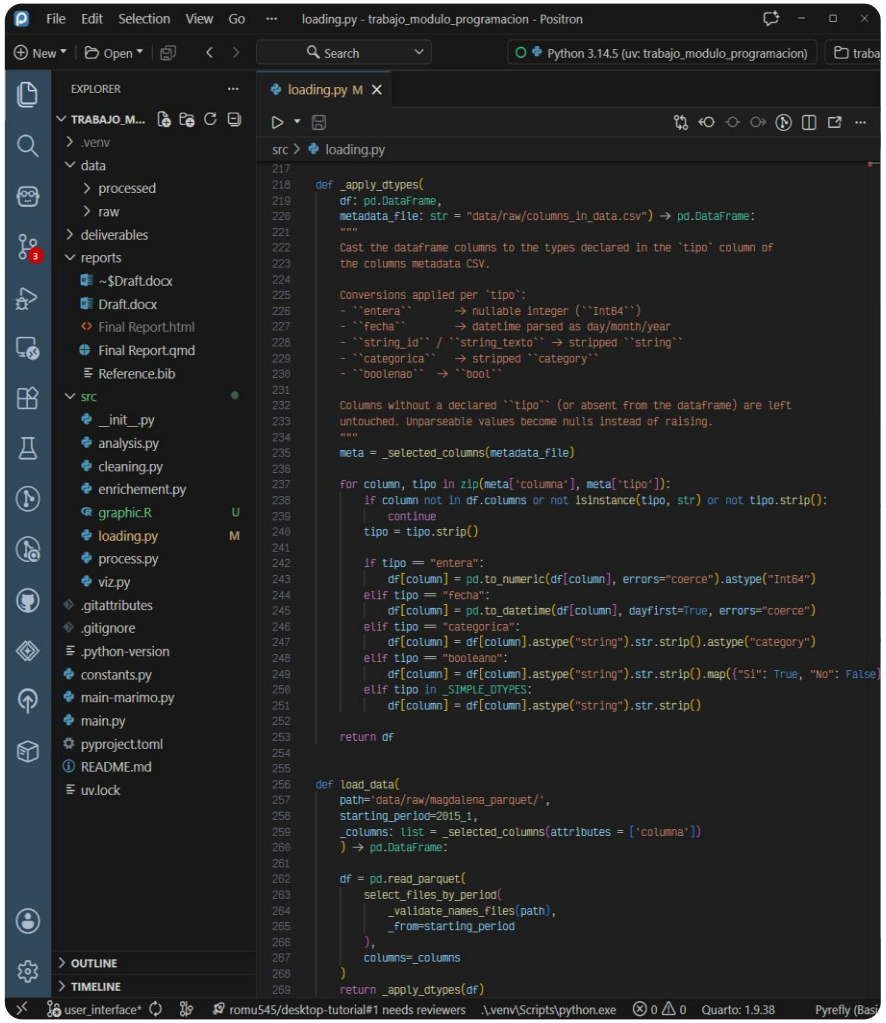
Decisión: urbanas + calendario A + jornadas diurnas, tarde y unica → muestra final de **69 instituciones (40 oficiales · 29 no oficiales)**

Cómo organizamos el programa

- **Estructura básica de un proyecto de ciencia de datos**
- **Separación de responsabilidades:**

  Lógica de análisis (src/)

  Presentación (reports/).
- **Cada módulo, una función clara** y nombres descriptivos en inglés, snake_case.
- **Cada función que transforma** devuelve un nuevo DataFrame (no muta el original).
- **Constantes a nivel de módulo** y tipos explícitos en las funciones.
- **Manejo de excepciones y avisos:** FileNotFoundError, KeyError, ValueError, warnings.



FLUJO DE TRABAJO

El pipeline en cuatro etapas

1

Carga

`loading.py`

Valida los archivos, selecciona columnas y asigna el tipo correcto a cada una.

```python
def load_data(
    path='data/raw/magdalena_parquet/',
    starting_period=2015_1,
    _columns: list = _selected_columns(attributes = ['columna'])
    ) -> pd.DataFrame:

    df = pd.read_parquet(
        select_files_by_period(
            _validate_names_files(path),
            _from=starting_period
        ),
        columns=_columns
    )
    return _apply_dtypes(df)
```

2

Limpieza

`cleaning.py`

Unifica categorías y homologa los nombres de los colegios entre años.

```python
def cleaning_pipeline(
    df: pd.DataFrame,
    school_features_path: str,
    order_columns: list = None
) -> pd.DataFrame:

    df = _apply_categorical_mappings(df)
    df = _format_text_columns(df)
    df = _integrate_standardized_schools(df, school_features_path)
    df = _reorder_columns(df, order_columns)
    return df
```

3

Enriquecimiento

`enrichement.py`

Crea columnas derivadas: año, semestre y edad del estudiante.

```python
def enrich_all(
    df: pd.DataFrame,
    *,
    age_valid_range: tuple[int, int]      = (13, 30),
    expected_age:    int                  = 17,
) -> pd.DataFrame:

    out = add_period_columns(df)
    out = add_student_age(out, valid_range=age_valid_range)
    out = add_overage_flag(out, expected_age=expected_age)
    out = add_ordinal_encodings(out)
    return out
```

4

Procesamiento

`process.py`

Filtra, agrega por colegio/año y exige continuidad temporal.

```python
def filter_data(
    df: pd.DataFrame,
    *,
    semester: Semester | None = None,
    calendar: Calendar | list[Calendar] | None = None,
    location: Location | list[Location] | None = None,
    grade: Grade | list[Grade] | None = None,
    nature: Nature | list[Nature] | None = None,
    exclude_shifts: list[Shift] | None = None,
    year_from: int | None = None,
    year_to: int | None = None,
) -> pd.DataFrame:
```

ENRIQUECIMIENTO

Columnas que creamos nosotros

Tiempo

`anio_prueba`
`semestre_prueba`

Separan el periodo (20152 → 2015 · sem. 2). Habilitan todo el análisis temporal.

Edad

`estu_edad_prueba`
`estu_extraedad`

Edad del estudiante en el examen y marca de extraedad para grado 11.

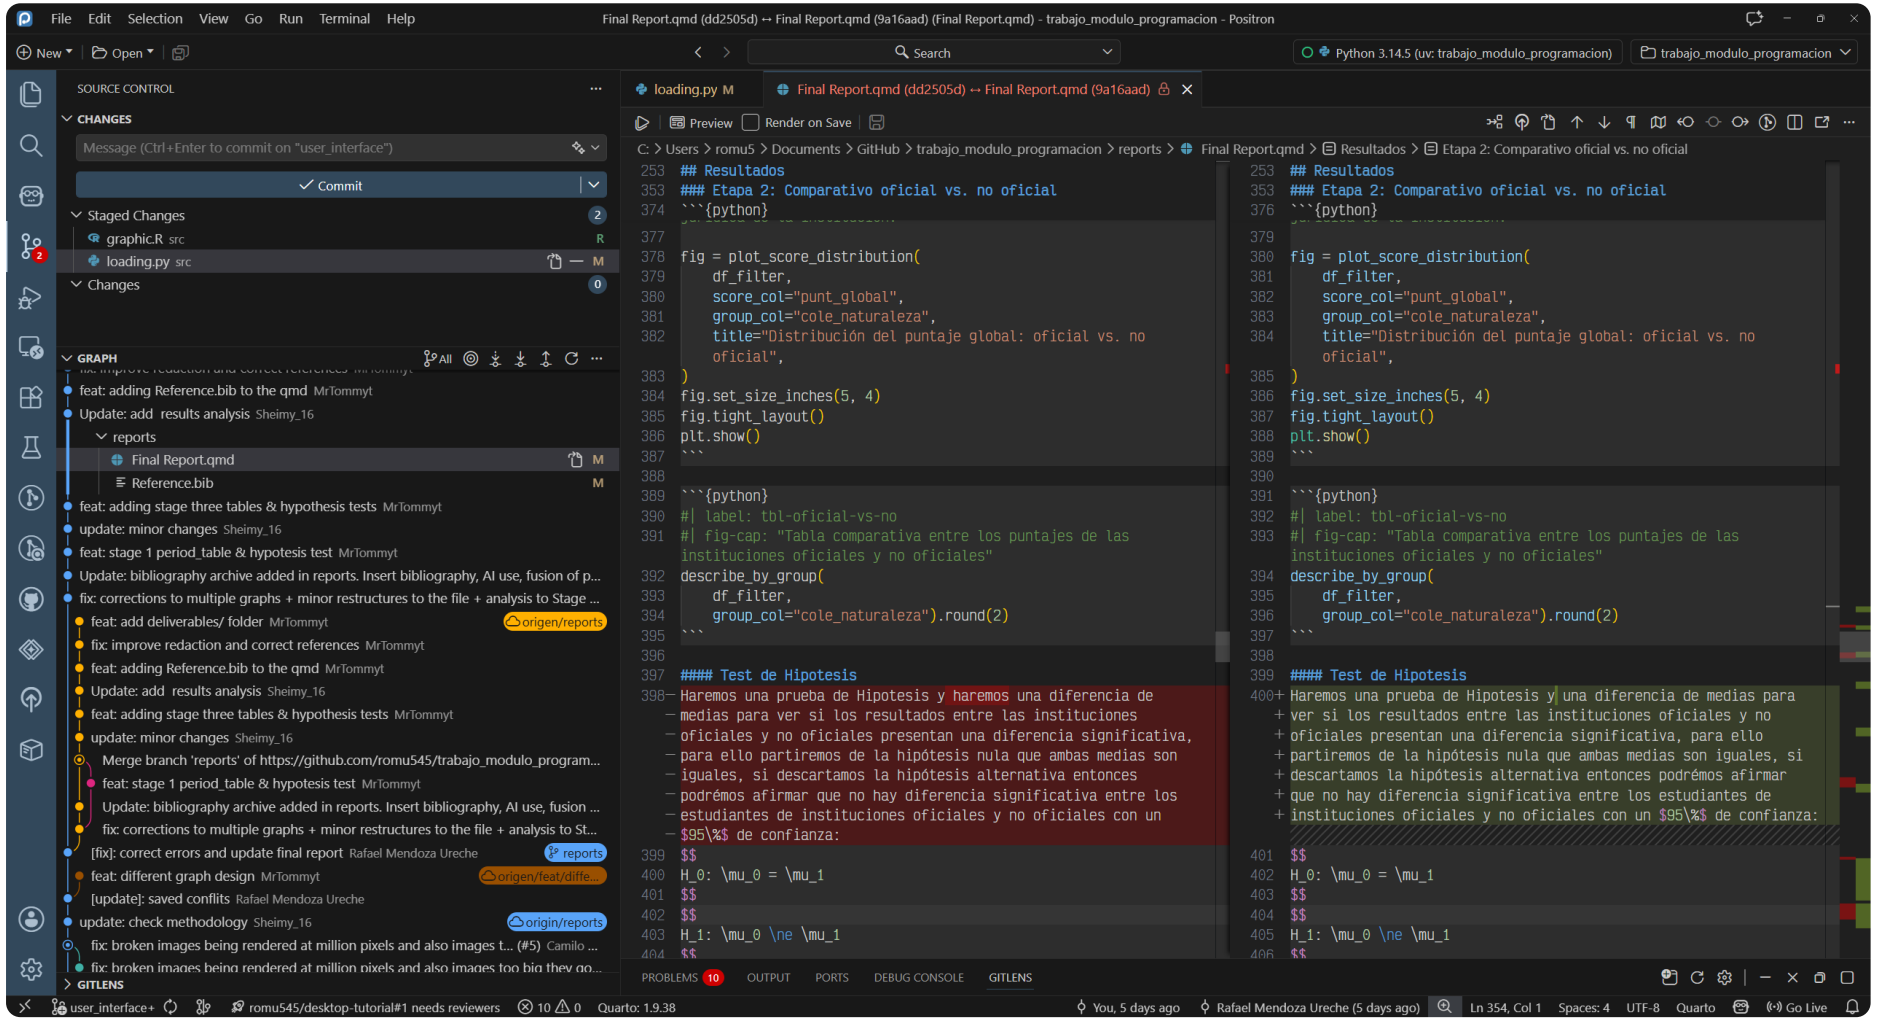
Hogar (×6)

`fami_estrato_num`
`fami_educ_madre_num`
…

Codificaciones ordinales del hogar: vuelven medibles las condiciones socioeconómicas.

Control de versiones

git + GitHub



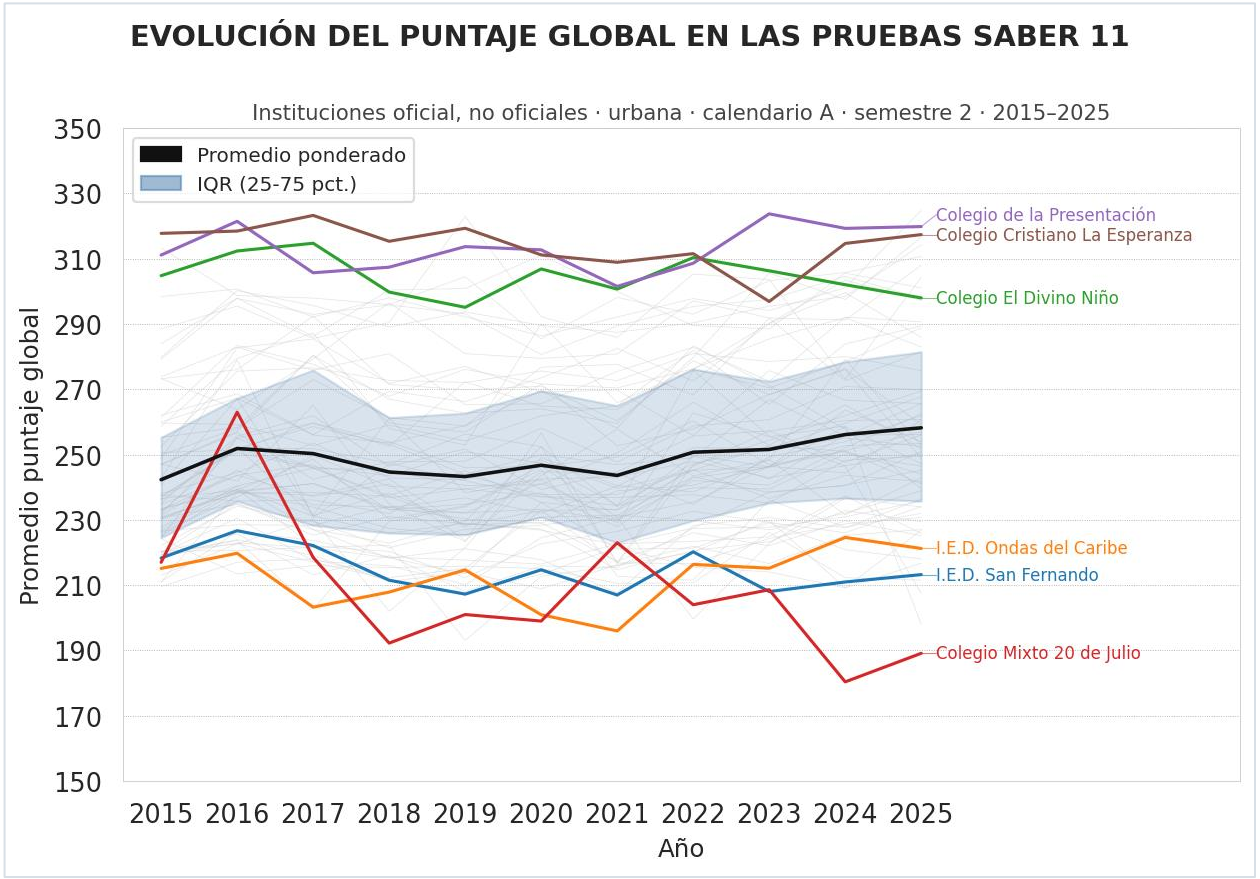
La tendencia: una mejora desigual

242 → 258

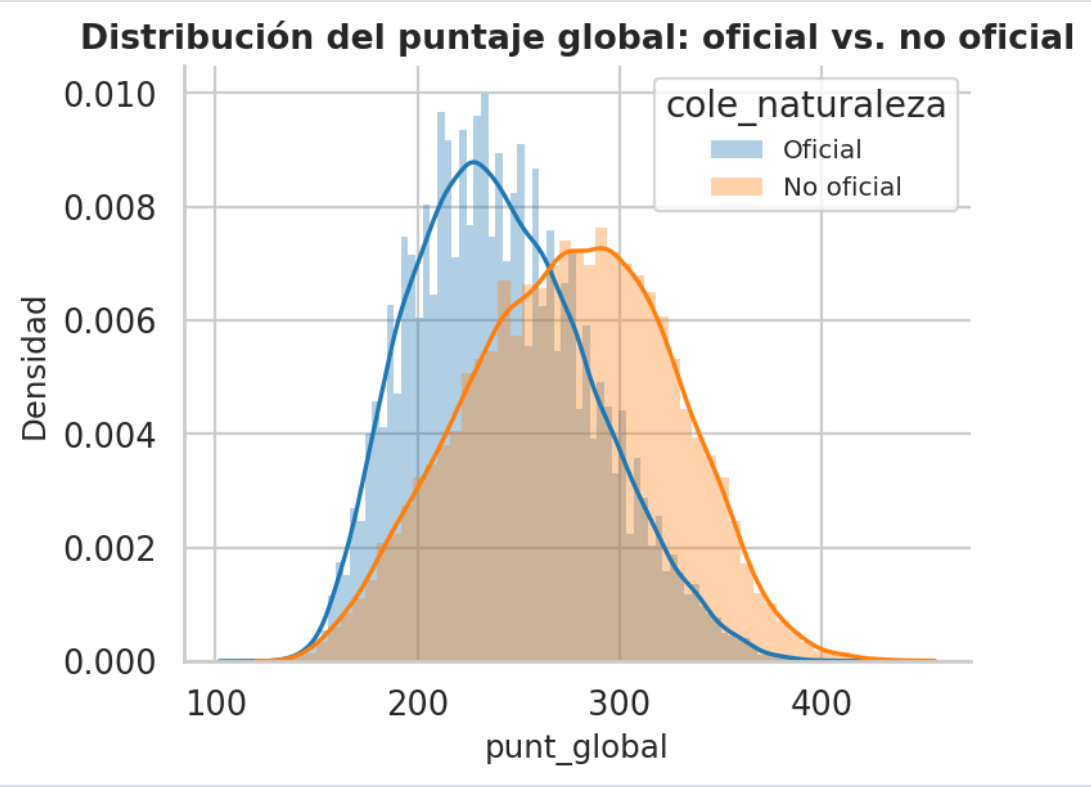
puntaje promedio ponderado (2015 → 2025)

- **+16 puntos** de aumento acumulado.
- **Caída en 2021** por la pandemia.
- **Recuperación sostenida** desde 2022.

Prueba t (2015 vs 2025): p < 0.05 ✓



Oficial vs. no oficial: una brecha clara



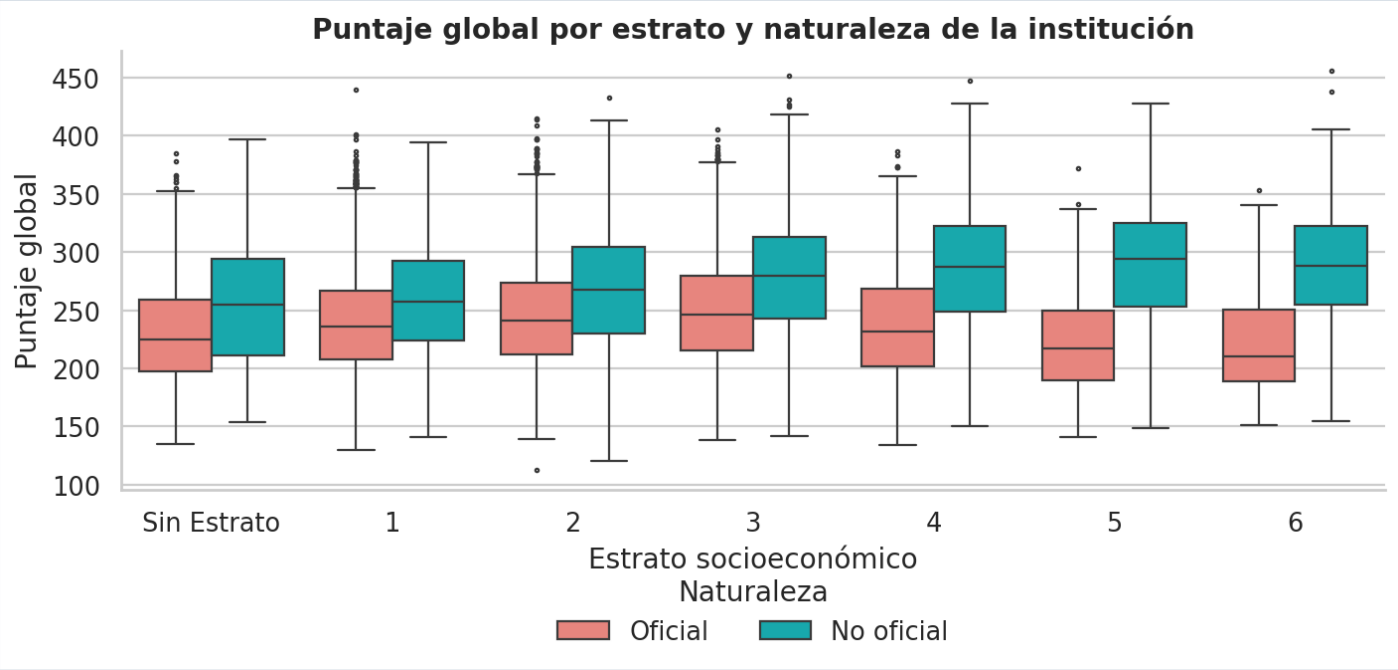
242
Oficial · media

275
No oficial · media

≈ 33 puntos de brecha
estable durante todo el periodo

Prueba de hipótesis: diferencia significativa (p < 0.05)

El peso de las condiciones del hogar



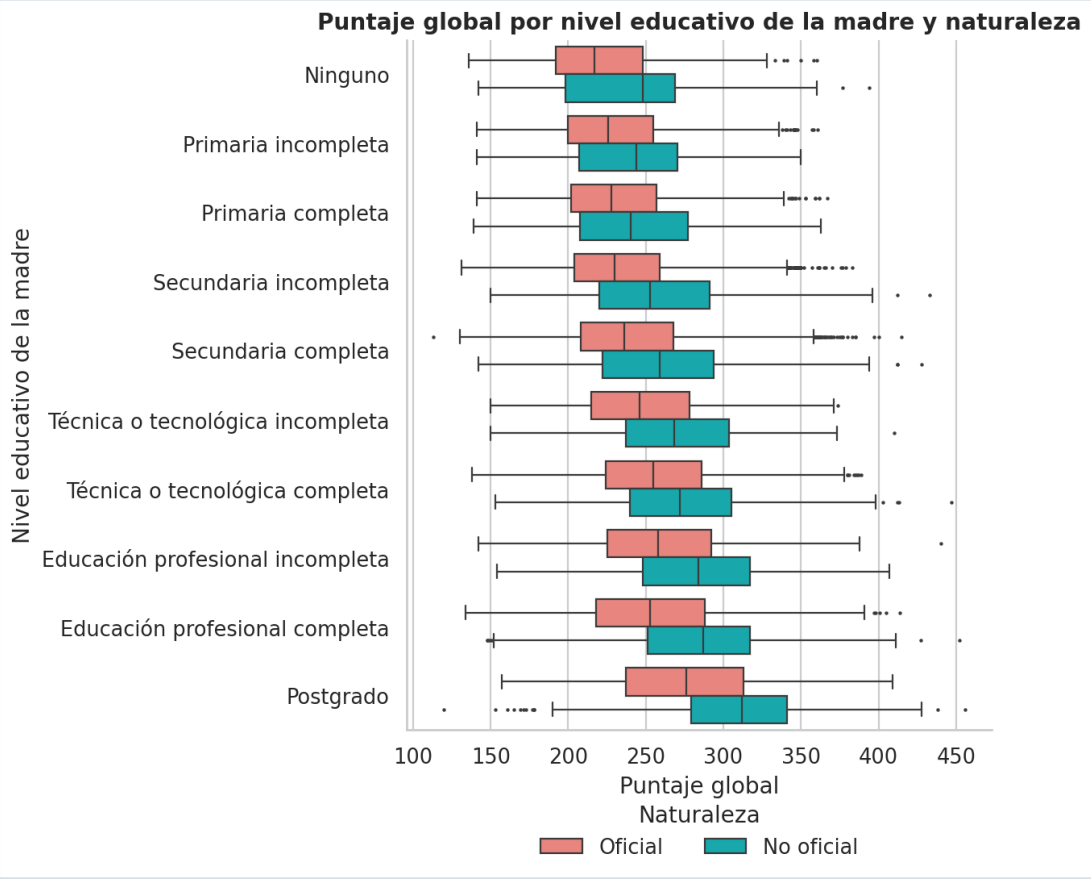
Puntaje por estrato y naturaleza de la institución

CORRELACIÓN DE SPEARMAN

de cada factor con el puntaje global

Educación de la madre	**0.32**
Educación del padre	**0.29**
Tiene computador	**0.21**
Número de libros	**0.21**
Estrato	**0.19**
Tiene internet	**0.19**
Tiene automóvil	**0.17**

Educación de la madre y acceso a internet



- **La educación de la madre** es el factor más asociado al desempeño.
- **A mayor nivel educativo,** mayor el puntaje, en ambos tipos de colegio.
- **Las no oficiales** se mantienen por encima en todos los niveles.

Acceso a internet en el hogar

Los estudiantes con internet puntúan significativamente más alto ($p < 0.05$).

CIERRE

Conclusiones

- **Mejora significativa pero desigual** (con el golpe del COVID en 2021).
- **Brecha estructural** entre oficiales y no oficiales (~33 puntos).
- **El contexto familiar pesa** tanto o más que la escuela.
- **La educación de la madre** es el factor más asociado al desempeño.
- **Las políticas solo escolares** tienen un alcance limitado.

El desempeño en Santa Marta depende, en buena parte, de factores que están fuera del aula.

TRANSPARENCIA

Uso de inteligencia artificial

Usamos Claude Code y ChatGPT como apoyo de programación en tareas concretas:

Pingouin

Consultar funciones para las pruebas estadísticas.

R → Python

Traducir un gráfico hecho primero en ggplot2.

Depuración

Corregir errores puntuales del código.

Bibliografía

Ordenar y citar las referencias.

Las herramientas fueron un apoyo técnico. Los objetivos, las decisiones metodológicas y la interpretación de los resultados fueron responsabilidad del equipo.

¡Gracias!

Análisis de las pruebas Saber 11 en Santa Marta · 2015–2025

Rafael Mendoza-Ureche · **Sheimy Lozano-Bustamante** · **Camilo Benavides-Jiménez**

Universidad del Magdalena